



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université des Sciences et de la Technologie Houari Boumediene

Faculté Informatique

Département IA & SD

Filière : Informatique

Spécialité : SII

Rapport TPS RCR2

Réaliser par :

Korreh Mohamed El hadi

Daoud Youcef

Professeur :

Moulai Hajer

TP 1 : Théorie de Dempster-Shafer	1
Contexte : Diagnostic médical basé sur la théorie des fonctions de croyance	1
1. Introduction.....	1
2. Problématique.....	1
3. Cadre de discernement	1
4. Fonctions de masse	1
5. Croyance et plausibilité	2
6. Combinaison des avis	3
7. Interprétation des résultats	4
8. Conclusion	4
TP 2 : Contrôleur Flou.....	5
1. Introduction.....	5
2. Contexte du Problème.....	5
3. Méthodologie : Logique Floue.....	6
3.1. Introduction à la Logique Floue.....	6
3.2. Application au Problème	6
4. Implémentation du Système de Contrôle Flou	6
4.1. Définition des Ensembles Flous.....	6
3.2. Règles d'Inférence	8
3.3. Inférence Floue et Défuzzification.....	9
4. Résultats	9
4.1. Valeurs d'Entrée	9
4.2. Résultats de l'Inférence Floue	9
4.3. Défuzzification	10
4.4. Interprétation	10
5. Conclusion	10
TP 3 : Réseaux bayésien	11
1. Introduction :.....	11
2. Implémenter un graphe à connexions multiples	12
2.1. Contexte du problème.....	12
1. Facteurs de risque :	12
2. Symptômes :	12
3. Maladie grave :	12
2.2. Variables et relations.....	13
2.3. Structure du réseau bayésien.....	13
2.4. Distributions de probabilité.....	14

Distribution a priori pour F1 :	14
Distribution a priori pour F2 :	14
Distribution conditionnelle pour S1 :	14
Distribution conditionnelle pour S2 :	14
2.5. Inférence.....	15
Algorithme d'inférence : Élimination de variables (Variable Elimination)	15
Principe de l'algorithme	15
Étapes de l'algorithme.....	15
Autres algorithmes d'inférence dans pgmpy	16
Question	16
Résultat attendu	16
3. Conclusion	17
TP4 : Inférence logique et propagation graphique en théorie des possibilités	18
Introduction.....	18
Étape 1 : Utilisation d'un algorithme de propagation pour les réseaux possibilistes.....	18
Étape 2 : Exécution des fichiers.....	19
Étape 3 : Évaluations	19
Une évidence	19
Deux evidences.....	20
Conclusion	21

TP 1 : Théorie de Dempster-Shafer

Contexte : Diagnostic médical basé sur la théorie des fonctions de croyance

1. Introduction

La théorie des fonctions de croyance, également connue sous le nom de théorie de Dempster-Shafer, est une approche mathématique pour modéliser l'incertitude et combiner des informations provenant de sources multiples. Elle est particulièrement utile dans des domaines où les décisions doivent être prises sur la base d'avis d'experts partiels ou incertains. Dans ce rapport, nous illustrons l'application de cette théorie à un problème de diagnostic médical, où plusieurs experts évaluent un patient présentant des symptômes pouvant correspondre à plusieurs maladies.

2. Problématique

Un patient présente des symptômes qui pourraient être associés à plusieurs maladies. Trois experts médicaux sont consultés pour établir un diagnostic. Chaque expert a une opinion différente sur les maladies possibles, mais ces opinions sont incertaines. L'objectif est de combiner les avis des experts pour obtenir un diagnostic plus fiable.

3. Cadre de discernement

Le cadre de discernement représente l'ensemble des maladies possibles. Dans cet exemple, les maladies sont représentées par des ensembles :

- **$\{a\}$** : Maladie A.
- **$\{b\}$** : Maladie B.
- **$\{c\}$** : Maladie C.
- **$\{a, b\}$** : Maladie A ou B.
- **$\{b, c\}$** : Maladie B ou C.
- **$\{a, b, c\}$** : Maladie A, B ou C (incertitude totale).

4. Fonctions de masse

Chaque expert fournit une fonction de masse qui représente son degré de croyance en chaque maladie ou combinaison de maladies. Les fonctions de masse des experts sont les suivantes :

1. Expert 1 (m1) :

- **{a, b}** : 60% de croyance (Maladie A ou B).
- **{c, b}** : 30% de croyance (Maladie B ou C).
- **{a}** : 10% de croyance (Maladie A).
- **{d, a}**: 0% de croyance (Maladie A ou D, non pertinente ici).

2. Expert 2 (m2) :

- **{c, a}** : 50% de croyance (Maladie A ou C).
- **{c}** : 30% de croyance (Maladie C).
- **{c, a, b}** : 20% de croyance (Maladie A, B ou C, incertitude totale).

3. Expert 3 (m3) :

- **{c, b}** : 80% de croyance (Maladie B ou C).
- **{}** : 20% de croyance (incertitude totale).

```
Creating mass functions
m_1 = {{ 'a', 'b':0.6; {'c', 'b':0.3; {'a':0.1; {'d', 'a':0.0}
m_2 = {{ 'c', 'a':0.5; {'c':0.3; {'c', 'a', 'b':0.2}
m_3 = {{ 'c', 'b':0.8; set():0.2} (unnormalized mass function)
```

Figure 1: Résultat Fonctions de masse

5. Croyance et plausibilité

La **croyance** (*bel*) mesure la confiance totale en une maladie ou un ensemble de maladies. La **plausibilité** (*pl*) mesure la plausibilité maximale d'une maladie ou d'un ensemble de maladies. Les résultats pour chaque expert sont les suivants :

1. Expert 1 :

- Croyance en **{a, b}** : 70% (inclut les masses de **{a, b}** et **{a}**).
- Plausibilité en **{a, b}** : 100% (aucune preuve contre cette hypothèse).

2. Expert 2 :

- Croyance en **{c}** : 30%.
- Plausibilité en **{c}** : 100%.

3. Expert 3 :

- Croyance en **{c, b}** : 80%.

- Plausibilité en **{c, b}** : 80%.

```
Croyance et possibilité pour l'expert 1
bel_1 = {frozenset(): 0.0, frozenset({'c'}): 0.0, frozenset({'a'}): 0.1, frozenset({'b'}): 0.0, frozenset({'a', 'c'}): 0.1, frozenset({'c', 'b'}): 0.3, frozenset({'a', 'b'}): 0.7, frozenset({'a', 'c', 'b'}): 1.0}
pl_1 = {frozenset(): 0.0, frozenset({'c'}): 0.3, frozenset({'a'}): 0.7, frozenset({'b'}): 0.8999999999999999, frozenset({'a', 'c'}): 1.0, frozenset({'c', 'b'}): 0.8999999999999999, frozenset({'a', 'b'}): 1.0, frozenset({'a', 'c', 'b'}): 1.0}
Croyance et possibilité pour l'expert 2
bel_2 = {frozenset(): 0.0, frozenset({'c'}): 0.3, frozenset({'a'}): 0.0, frozenset({'b'}): 0.0, frozenset({'a', 'c'}): 0.8, frozenset({'c', 'b'}): 0.3, frozenset({'a', 'b'}): 0.0, frozenset({'a', 'c', 'b'}): 1.0}
pl_2 = {frozenset(): 0.0, frozenset({'c'}): 1.0, frozenset({'a'}): 0.7, frozenset({'b'}): 0.2, frozenset({'a', 'c'}): 1.0, frozenset({'c', 'b'}): 1.0, frozenset({'a', 'b'}): 0.7, frozenset({'a', 'c', 'b'}): 1.0}
Croyance et possibilité pour l'expert 3
bel_3 = {frozenset(): 0.0, frozenset({'c'}): 0.0, frozenset({'b'}): 0.0, frozenset({'c', 'b'}): 0.8}
pl_3 = {frozenset(): 0.0, frozenset({'c'}): 0.8, frozenset({'b'}): 0.8, frozenset({'c', 'b'}): 0.8}
```

Figure 2: résultat de calcul Croyance et plausibilité

6. Combinaison des avis

La règle de **Dempster-Shafer** est utilisée pour combiner les avis des experts. Les résultats de la combinaison sont les suivants :

1. Combinaison de Expert 1 et Expert 2 :

- **{a}** : 46,8% de croyance (Maladie A).
- **{c}** : 30,4% de croyance (Maladie C).
- **{a, b}** : 15,2% de croyance (Maladie A ou B).
- **{c, b}** : 7,6% de croyance (Maladie B ou C).

2. Combinaison de Expert 2 et Expert 3 :

- **{c}** : 80% de croyance (Maladie C).
- **{c, b}** : 20% de croyance (Maladie B ou C).

3. Combinaison de Expert 1 et Expert 3 :

- **{b}** : 66,7% de croyance (Maladie B).
- **{c, b}** : 33,3% de croyance (Maladie B ou C).

4. Combinaison de Expert 1, Expert 2 et Expert 3 :

- **{a}** : 46,8% de croyance (Maladie A).
- **{c}** : 30,4% de croyance (Maladie C).
- **{a, b}** : 15,2% de croyance (Maladie A ou B).
- **{c, b}** : 7,6% de croyance (Maladie B ou C).

```

Dempster-Shafer Combinaison rule
Dempster-Shafer Combinaison rule for m_1 and m_2 = {'a':0.46835443037974683; {'c':0.30379746835443033; {'a', 'b':0.15189873417721517; {'c', 'b':0.07594936708860758}
Dempster-Shafer Combinaison rule for m_2 and m_3 = {'c':0.7999999999999999; {'c', 'b':0.20000000000000004}
Dempster-Shafer Combinaison rule for m_1 and m_3 = {'b':0.6666666666666666; {'c', 'b':0.3333333333333333}
Dempster-Shafer Combinaison rule for m_1, m_2 and m_3 = {'a':0.46835443037974683; {'c':0.30379746835443033; {'a', 'b':0.15189873417721517; {'c', 'b':0.07594936708860758}
Dempster-Shafer Combinaison rule for m_2, m_1 and m_3 = {'a':0.46835443037974683; {'c':0.30379746835443033; {'a', 'b':0.15189873417721517; {'c', 'b':0.07594936708860758}
Dempster-Shafer Combinaison rule for m_3, m_1 and m_2 = {'b':0.6666666666666666; {'c', 'b':0.3333333333333333}

```

Figure 3: Résultat de Combinaison

7. Interprétation des résultats

Les résultats montrent que :

- La combinaison **d'Expert 1 et Expert 2** suggère que la **Maladie A** est la plus probable (46,8% de croyance).
- La combinaison **d'Expert 2 et Expert 3** suggère que la **Maladie C** est la plus probable (80% de croyance).
- La combinaison **d'Expert 1 et Expert 3** suggère que la **Maladie B** est la plus probable (66,7% de croyance).

Ces résultats permettent de réduire l'incertitude et de focaliser sur les maladies les plus probables en fonction des avis combinés des experts.

8. Conclusion

Dans ce contexte de diagnostic médical, la théorie des fonctions de croyance permet de modéliser les avis incertains des experts, de calculer des mesures de croyance et de plausibilité, et de combiner les avis pour obtenir un diagnostic plus fiable. Cette approche est utile dans de nombreux domaines où l'incertitude et la fusion d'avis d'experts sont importantes, comme la médecine, la finance, la gestion des risques, ou la détection de pannes industrielles.

TP 2 : Contrôleur Flou

1. Introduction

La logique floue est une extension de la logique classique qui permet de traiter des concepts imprécis ou incertains. Contrairement à la logique binaire traditionnelle (vrai/faux), la logique floue utilise des degrés d'appartenance pour représenter des valeurs intermédiaires. Elle est largement utilisée dans les systèmes de contrôle, la prise de décision, et la modélisation de systèmes complexes où les données sont souvent imprécises ou subjectives.

Dans ce rapport, nous présentons un problème concret résolu à l'aide d'un système de contrôle flou implémenté en Python avec la bibliothèque **fuzzylogic**. Le problème consiste à déterminer la force d'un résonateur mécanique en fonction de deux paramètres d'entrée : la **masse** et l'**amortisseur**. Nous expliquerons comment la logique floue a été appliquée pour résoudre ce problème, ainsi que les résultats obtenus.

2. Contexte du Problème

Le résonateur mécanique est un système composé d'une masse et d'un amortisseur. La force résultante du système dépend de ces deux paramètres. Cependant, la relation entre la masse, l'amortisseur et la force n'est pas linéaire et peut être difficile à modéliser avec des équations mathématiques précises. De plus, les valeurs de la masse et de l'amortisseur peuvent varier dans des plages continues, ce qui rend le problème idéal pour l'application de la logique floue.

L'objectif est de concevoir un système de contrôle flou qui, à partir des valeurs de la masse et de l'amortisseur, détermine la force résultante du résonateur mécanique.

3. Méthodologie : Logique Floue

3.1. Introduction à la Logique Floue

La logique floue repose sur trois concepts clés :

- **Ensembles flous** : Contrairement aux ensembles classiques (où un élément appartient ou n'appartient pas à un ensemble), les ensembles flous permettent à un élément d'appartenir partiellement à plusieurs ensembles. Par exemple, une masse peut être à la fois "petite" et "moyenne" avec des degrés d'appartenance différents.
- **Fonctions d'appartenance** : Ces fonctions définissent comment une valeur d'entrée est associée à un ensemble flou. Les fonctions couramment utilisées sont triangulaires, trapézoïdales ou gaussiennes.
- **Règles d'inférence** : Ces règles relient les ensembles flous des entrées aux ensembles flous de la sortie. Par exemple, "Si la masse est petite et l'amortisseur est faible, alors la force est moyenne."

3.2. Application au Problème

Dans ce problème, nous avons défini :

- **Deux entrées** : Masse et Amortisseur.
 - **Une sortie** : Force.
- **Ensembles flous** pour chaque entrée et sortie, avec des fonctions d'appartenance trapézoïdales.
- **Règles d'inférence** pour relier les entrées à la sortie.

4. Implémentation du Système de Contrôle Flou

4.1. Définition des Ensembles Flous

- **Masse** : Les ensembles flous sont définis comme
Très petite (TP) : Triangle (0, 24, 37)
Petite (PE) : Triangle (24, 37, 59)
Moyenne (MO) : Triangle (37, 59, 71)
Grande (GD) : Triangle (59, 71, 90)




Figure 4 Graphique : Les ensembles flous de la masse

- Amortisseur :** Les ensembles flous sont définis comme
 - Très faible (TF) : Trapèze (10, 20, 35, 40)
 - Faible (FA) : Trapèze (35, 40, 65, 75)
 - Moyenne (MO) : Trapèze (65, 75, 100, 110)
 - Fort (FO) : Trapèze (100, 110, 125, 140)




Figure 5 Graphique : Les ensembles flous de l'amortisseur

- **Force** : Les ensembles flous sont définis comme
 Petite (PE) : Trapèze (20, 35, 35, 45)
 Moyenne (MO) : Trapèze (35, 45, 45, 70)
 Grande (GR) : Trapèze (45, 70, 70, 85)
 Très grande (TG) : Trapèze (70, 85, 85, 100)




Figure 6 Graphique : Les ensembles flous de la force

3.2. Règles d'Inférence

Les règles d'inférence sont définies pour relier les combinaisons des ensembles flous de la masse et de l'amortisseur aux ensembles flous de la force. Par exemple :

- Si la masse est **Très petite (TP)** et l'amortisseur est **Très faible (TF)**, alors la force est **Petite (PE)**.
- Si la masse est **Grande (GD)** et l'amortisseur est **Fort (FO)**, alors la force est **Très grande (TG)**.

```

(Masse.TP, Amortisseur.TF): Force.PE,
(Masse.PE, Amortisseur.TF): Force.MO,
(Masse.MO, Amortisseur.TF): Force.MO,
(Masse.GD, Amortisseur.TF): Force.GR,
(Masse.TP, Amortisseur.FA): Force.PE,
(Masse.PE, Amortisseur.FA): Force.MO,
(Masse.MO, Amortisseur.FA): Force.GR,
(Masse.GD, Amortisseur.FA): Force.GR,
(Masse.TP, Amortisseur.MO): Force.PE,
(Masse.PE, Amortisseur.MO): Force.GR,
(Masse.MO, Amortisseur.MO): Force.MO,
(Masse.GD, Amortisseur.MO): Force.TG,
(Masse.TP, Amortisseur.FO): Force.PE,
(Masse.PE, Amortisseur.FO): Force.GR,
(Masse.MO, Amortisseur.FO): Force.TG,
(Masse.GD, Amortisseur.FO): Force.TG,

```

Figure 7 : Règles d'Inférence

3.3. Inférence Floue et Défuzzification

- **Inférence floue** : La méthode de **Mamdani** est utilisée pour calculer les degrés d'appartenance des ensembles flous de la force en fonction des règles d'inférence.
- **Défuzzification** : La méthode du **centre de gravité** est utilisée pour obtenir une valeur précise de la force à partir des ensembles flous.

4. Résultats

4.1. Valeurs d'Entrée

- **Masse** : 40
- **Amortisseur** : 105

4.2. Résultats de l'Inférence Floue


```

Force Petite : 0.0
Force Moyenne : 0.136363636363635
Force Grande : 0.5
Force Très Grande : 0.0

```

Figure 8 Résultats de l'Inférence Floue

4.3. Défuzzification



```
Centre de gravité (Force) : 66.26690182245738
```

Figure 9 Résultat de Défuzzification

4.4. Interprétation

La force résultante est principalement influencée par l'ensemble **Grande (GR)** avec un degré d'appartenance de 0.5. La valeur précise de la force, obtenue par défuzzification, est de 66.27.

5. Conclusion

Le système de contrôle flou a permis de résoudre efficacement le problème de détermination de la force d'un résonateur mécanique en fonction de la masse et de l'amortisseur. La logique floue offre une approche flexible et intuitive pour modéliser des systèmes complexes où les relations entre les variables ne sont pas strictement définies.

Les résultats montrent que pour une masse de 40 et un amortisseur de 105, la force résultante est principalement **Grande (GR)** avec une valeur précise de **66.27**. Cette approche peut être étendue à d'autres problèmes similaires dans le domaine de l'ingénierie mécanique ou des systèmes de contrôle.

TP 3 : Réseaux bayésien

1. Introduction :

Les réseaux bayésiens sont des modèles graphiques probabilistes qui permettent de représenter et de raisonner sur des systèmes complexes en utilisant des relations de dépendance entre variables. Ils combinent la théorie des probabilités et la théorie des graphes pour fournir un cadre puissant et intuitif pour l'inférence et la prise de décision sous incertitude.

Un réseau bayésien est un graphe orienté acyclique (DAG) où :

Les nœuds représentent des variables aléatoires (par exemple, des symptômes, des causes, des observations).

Les arêtes représentent des dépendances probabilistes entre les variables.

Les tables de probabilité (CPDs, Conditional Probability Distributions) associées à chaque nœud définissent les probabilités conditionnelles de la variable étant donné ses parents dans le graphe.

$$P(B, E, A, C, R) = P(B)P(E)P(A | B, E)P(R | E)P(C | A).$$




Figure 10: Un exemple pour le réseau bayésien

Les réseaux bayésiens sont très utiles pour représenter la connaissance car ils ont une faible complexité en temps et l'espace. Pour l'apprentissage automatique, il suffit d'utiliser un petit ensemble des données et pendant l'inférence, le temps pour trouver un résultat est petit.

Nous pouvons utiliser ces réseaux pour l'analyse causale, la décision, le diagnostic médical et les scénarios qui expliquent la preuve etc.

Généralement, pour l'inférence, le graph sera transformé en un arbre de jonction en regroupant des nœuds.

2. Implémenter un graphe à connexions multiples

Le but est de prédire la probabilité qu'un patient ait une maladie grave (M) en fonction de plusieurs facteurs de risque et symptômes interconnectés. Voici une explication détaillée du problème et du code :

2.1. Contexte du problème

Vous travaillez sur un système de diagnostic médical pour prédire la probabilité qu'un patient ait une maladie grave (M) en fonction des éléments suivants :

1. Facteurs de risque :

- **F1** : Facteur de risque génétique (par exemple, antécédents familiaux).
- **F2** : Facteur de risque environnemental (par exemple, exposition à des toxines).

2. Symptômes :

- **S1** : Symptôme 1 (par exemple, fièvre).
- **S2** : Symptôme 2 (par exemple, fatigue).
- **S3** : Symptôme 3 (par exemple, douleur).

3. Maladie grave :

- **M** : Maladie grave (par exemple, une maladie chronique).

Les symptômes et les facteurs de risque sont interconnectés, créant un **graphe à connexions multiples** où plusieurs chemins relient certains nœuds.

2.2. Variables et relations

1. **F1** (Facteur de risque génétique) :
 - États : **0** (absent), **1** (présent).
 - Influence : **S1** et **S3**.
2. **F2** (Facteur de risque environnemental) :
 - États : **0** (absent), **1** (présent).
 - Influence : **S1** et **S2**.
3. **S1** (Symptôme 1) :
 - États : **0** (absent), **1** (présent).
 - Influence : **S2** et **M**.
4. **S2** (Symptôme 2) :
 - États : **0** (absent), **1** (présent).
 - Influence : **S3** et **M**.
5. **S3** (Symptôme 3) :
 - États : **0** (absent), **1** (présent).
 - Influence : **M**.
6. **M** (Maladie grave) :
 - États : **0** (absent), **1** (présent).
 - Dépend de : **S1**, **S2** et **S3**

2.3. Structure du réseau bayésien

Le réseau bayésien est représenté par le graphe suivant :




Figure 11: Réseau Bayésien : Diagnostic Médical

2.4. Distributions de probabilité

Distribution a priori pour F1 :

- **$P(F1 = 0) = 0.8$** : 80 % de chances que le facteur de risque génétique soit absent.
- **$P(F1 = 1) = 0.2$** : 20 % de chances que le facteur de risque génétique soit présent.

Distribution a priori pour F2 :

- **$P(F2 = 0) = 0.7$** : 70 % de chances que le facteur de risque environnemental soit absent.
- **$P(F2 = 1) = 0.3$** : 30 % de chances que le facteur de risque environnemental soit présent.

Distribution conditionnelle pour S1 :

- **$P(S1 = 0 | F1 = 0, F2 = 0) = 0.9$** : Si les deux facteurs de risque sont absents, 90 % de chances que le symptôme 1 soit absent.
- **$P(S1 = 1 | F1 = 1, F2 = 1) = 0.8$** : Si les deux facteurs de risque sont présents, 80 % de chances que le symptôme 1 soit présent.

Distribution conditionnelle pour S2 :

- **$P(S2 = 0 | F2 = 0, S1 = 0) = 0.8$** : Si le facteur environnemental est absent et le symptôme 1 est absent, 80 % de chances que le symptôme 2 soit absent.
- **$P(S2 = 1 | F2 = 1, S1 = 1) = 0.7$** : Si le facteur environnemental est présent et le symptôme 1 est présent, 70 % de chances que le symptôme 2 soit présent.

1. Distribution conditionnelle pour S3 :

- **$P(S3 = 0 | F1 = 0, S2 = 0) = 0.9$** : Si le facteur génétique est absent et le symptôme 2 est absent, 90 % de chances que le symptôme 3 soit absent.
- **$P(S3 = 1 | F1 = 1, S2 = 1) = 0.6$** : Si le facteur génétique est présent et le symptôme 2 est présent, 60 % de chances que le symptôme 3 soit présent.

2. Distribution conditionnelle pour M

- **$P(M = 0 | S1 = 0, S2 = 0, S3 = 0) = 0.95$** : Si les trois symptômes sont absents, 95 % de chances que la maladie soit absente.
- **$P(M = 1 | S1 = 1, S2 = 1, S3 = 1) = 0.9$** : Si les trois symptômes sont présents, 90 % de chances que la maladie soit présente.

2.5. Inférence

L'algorithme d'inférence utilisé est l'élimination de variables (Variable Elimination), qui est implémenté dans la bibliothèque **pgmpy** via la classe **VariableElimination**.

Algorithme d'inférence : Élimination de variables (Variable Elimination)

Principe de l'algorithme

L'élimination de variables est une méthode d'inférence exacte utilisée pour calculer des probabilités conditionnelles dans un réseau bayésien. Elle fonctionne en éliminant progressivement les variables non pertinentes pour le calcul de la probabilité d'intérêt, en combinant les distributions de probabilité locales (CPDs) et en marginalisant les variables inutiles.

Étapes de l'algorithme

1. Sélection des variables à éliminer : Identifie les variables qui ne sont pas dans la requête (variables d'intérêt) ni dans les évidences (variables observées).
2. Combinaison des CPDs : Combine les distributions de probabilité conditionnelle (CPDs) des variables à éliminer.
3. Marginalisation : Élimine les variables en les marginalisant (c'est-à-dire en sommant ou en intégrant leurs valeurs possibles).
4. Répétition : Répète les étapes 2 et 3 jusqu'à ce que toutes les variables non pertinentes soient éliminées.
5. Calcul final : Calcule la probabilité conditionnelle de la variable d'intérêt en utilisant les distributions restantes.

L'algorithme fournit des résultats exacts (contrairement à des méthodes approximatives comme l'échantillonnage

Il est efficace pour les réseaux bayésiens de taille modérée ou pour les requêtes spécifiques où peu de variables doivent être éliminées.

Il peut être utilisé pour calculer des probabilités conditionnelles, des distributions marginales, ou des requêtes plus complexes.

Autres algorithmes d'inférence dans pgmpy

pgmpy prend en charge d'autres algorithmes d'inférence, notamment :


- **Belief Propagation** : Utilisé pour les réseaux à structure arborescente ou polyarborescente.
- **Échantillonnage (Sampling)** : Méthodes approximatives comme l'échantillonnage de Gibbs ou Monte Carlo.
- **Inference exacte** : D'autres méthodes exactes comme l'énumération.

Question

Quelle est la probabilité de maladie ($M = 1$) si :

- Le facteur de risque génétique est présent ($F1 = 1$).
- Le facteur de risque environnemental est présent ($F2 = 1$).

Résultat attendu



```
Modèle valide ? True
+-----+-----+
| M      | phi(M) |
+=====+=====+
| M(0)   | 0.3776 |
+-----+-----+
| M(1)   | 0.6224 |
+-----+-----+
```

Figure 12: Résultat d'une question

- **P ($M = 0$) = 0.3776** : 37.76% de chances que la maladie soit absente.
- **P ($M = 1$) = 0.6224** : 62.24% de chances que la maladie soit présente.

3. Conclusion

Ce code modélise un problème complexe de diagnostic médical en utilisant un réseau bayésien à connexions multiples. Il permet de calculer la probabilité de maladie en fonction des facteurs de risque et des symptômes.

TP4 : Inférence logique et propagation graphique en théorie des possibilités

Introduction

Dans ce TP, nous allons mettre en œuvre l'inférence et la propagation graphique en théorie des possibilités à l'aide de l'outil PNT. Pour ce faire, nous utiliserons Cygwin, un émulateur Unix pour Windows, afin d'exécuter les programmes `passage.exe` et `inference.exe`.

Après avoir lancé l'outil, nous procéderons à une analyse des différents temps d'exécution pour la propagation et l'inférence dans des réseaux possibilistes correspondant à plusieurs structures : polyarbre, graphes faiblement connectés, graphes moyennement connectés et graphes fortement connectés.

Objectifs du TP

Ce TP vise à atteindre les objectifs suivants :

Comparer les temps d'exécution pour la propagation et l'inférence selon différents scénarios.

Tirer des conclusions à partir des résultats obtenus.

Utilisation de Cygwin

Le programme `passage.exe` associé au graphe possibiliste basé sur le produit la base de connaissance possibiliste quantitative correspondante. Ensuite, le programme `inference.exe` est utilisé pour lancer le processus d'inférence, qui consiste à calculer :

Le degré de possibilité d'une instance d'une variable d'intérêt.

Le temps nécessaire pour effectuer cette inférence.

Étape 1 : Utilisation d'un algorithme de propagation pour les réseaux possibilistes

Avant d'exécuter les programmes `passage.exe` et `inference.exe`, il est nécessaire de générer le graphe possibiliste en utilisant les scripts MATLAB `prop1evid` ou `prop2evid`.

Étape 2 : Exécution des fichiers

```
acer@LAPTOP-9D6T0DQH /home/licence
$ cat resultats
*****Résultats de la propagation graphique*****
nombre de variables: 20
nombre de parentsmax: 20
l'evidence: 20
variable d'interet: -1
possibilité conditionnelle de l'interet | evidences 2.000000
temps de propagation 2.000000 secondes

*****Résultats de l'inférence logique*****
le nombre de clauses dans les bases est de: 92871
la variable d'intérêt est inférée à partir de la base de pénalités
le coût de pénalité est de 0
avec un degré de possibilité correspondant est égale à :1.000000
la durée de l'inférence est: 371236 millisecondes
```

Étape 3 : Évaluations

Nous avons réalisé des évaluations en fonction du nombre de nœuds pour chaque scénario : **polyarbre**, **graphes faiblement connectés**, **graphes moyennement connectés** et **graphes fortement connectés**, en considérant une évidence, puis deux évidences.

- **Configuration des parents :**
 - **1 parent** : pour obtenir un polyarbre.
 - **3 parents** : pour un graphe faiblement connecté.
 - **10 parents** : pour un graphe moyennement connecté.
 - **20 parents** : pour un graphe fortement connecté.
- **Nombre de nœuds testés** : [5, 10, 15, 20,25].

Une évidence

nb nodes / nb de parents	1	3	10	20
5	48721	50234	52012	59732
10	53876	48973	54521	56984
15	51098	52456	56812	83665
20	52341	57892	55369	141926

Temps d'exécution de l'inférence en ms pour une évidence

nb nodes / nb de parents	1	3	10	20
5	0	0.020312	0.008142	0.012516
10	0	0.025843	0.014236	0.029768
15	0	0.033124	0.028174	0.032751
20	0	0.042189	0.036124	0.027004

Temps d'exécution de la propagation en secondes pour une évidence

Deux evidences

nb nodes / nb de parents	1	3	10	20
5	23781	25234	52012	69463
10	33256	38673	74521	87429
15	31798	42546	84080	154646
20	39995	57892	65369	371236

Temps d'exécution de la propagation en secondes pour deux évidences

nb nodes / nb de parents	1	3	10	20
5	1	1	1	1
10	0	2	1	2
15	1	1	2	2
20	0	1	2	2

Temps d'exécution de la propagation en secondes pour deux évidences

Conclusion

Ces travaux pratiques nous ont permis d'explorer les diverses logiques sur lesquelles repose le fonctionnement d'un système informatique. Nous avons appris à modéliser des problèmes issus de situations réelles, à générer des inférences, à utiliser des moteurs de raisonnement pour vérifier la validité de formules, à représenter graphiquement des informations, et enfin, à déduire des faits à partir des données analysées.